

## 7.4 奇异值分解

5.3 节和 7.1 节的对角化定理在许多应用中均很重要, 然而, 如我们所知, 不是所有矩阵都有分解式  $A = PDP^{-1}$ , 且  $D$  是对角的. 但分解  $A = QDP^{-1}$  对任意  $m \times n$  矩阵  $A$  都有可能! 这类特殊分解称为奇异值分解, 是线性代数应用中最有用的矩阵分解.

奇异值分解基于一般的矩阵对角化性质, 可以被长方形矩阵模仿: 一个对称矩阵  $A$  的特征值的绝对值表示度量  $A$  拉长或压缩一个向量 (特征向量) 的程度. 如果  $Ax = \lambda x$ , 且  $\|x\| = 1$ , 那么

$$\|Ax\| = \|\lambda x\| = |\lambda| \|x\| = |\lambda| \quad (1)$$

如果  $\lambda_1$  是具有最大数值的特征值, 那么对应的单位特征向量  $v_1$  确定一个由  $A$  的拉长影响最大的方向, 也就是说, (1) 式表示当  $x = v_1$  时,  $Ax$  的长度最大化, 且  $\|Av_1\| = |\lambda_1|$ . 这个对  $v_1$  和  $|\lambda_1|$  的描述对于长方形的矩阵来说也是类似的, 这将导致奇异值分解.

**例 1** 如果  $A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix}$ , 那么线性变换  $x \mapsto Ax$  将  $\mathbb{R}^3$  中的单位球  $\{x: \|x\| = 1\}$  映上到  $\mathbb{R}^2$  中的椭圆, 见图 7-13. 找出使得长度  $\|Ax\|$  最大的一个单位向量  $x$ , 且计算这个最大长度.




图 7-13 从  $\mathbb{R}^3$  到  $\mathbb{R}^2$  的一个变换

**解** 使  $\|Ax\|^2$  的值最大化的  $x$  同样使  $\|Ax\|$  的值最大化, 但  $\|Ax\|^2$  更容易计算. 注意到

$$\|Ax\|^2 = (Ax)^T(Ax) = x^T A^T A x = x^T (A^T A) x$$

由于  $(A^T A)^T = A^T A^{TT} = A^T A$ , 故  $A^T A$  也是一个对称矩阵. 所以, 现在的问题转化为在条件  $\|x\| = 1$  的限制下二次型  $x^T (A^T A) x$  的最大化. 利用 7.3 节的定理 6, 最大值就是矩阵  $A^T A$  的最大特征值  $\lambda_1$ , 同样, 最大值可以在  $A^T A$  的特征值  $\lambda_1$  对应的单位特征向量处获得.

对本例中的矩阵  $A$ ,

$$A^T A = \begin{bmatrix} 4 & 8 \\ 11 & 7 \\ 14 & -2 \end{bmatrix} \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix} = \begin{bmatrix} 80 & 100 & 40 \\ 100 & 170 & 140 \\ 40 & 140 & 200 \end{bmatrix}$$

矩阵  $A^T A$  的特征值是  $\lambda_1 = 360$ ,  $\lambda_2 = 90$  和  $\lambda_3 = 0$ , 对应的单位特征向量分别是

$$\mathbf{v}_1 = \begin{bmatrix} 1/3 \\ 2/3 \\ 2/3 \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} -2/3 \\ -1/3 \\ 2/3 \end{bmatrix}, \mathbf{v}_3 = \begin{bmatrix} 2/3 \\ -2/3 \\ 1/3 \end{bmatrix}$$

$\|A\mathbf{x}\|^2$  的最大值是 360, 且在  $\mathbf{x}$  为单位向量  $\mathbf{v}_1$  处获得. 向量  $A\mathbf{v}_1$  是图 7-13 中椭圆上离原点最远的点, 即

$$A\mathbf{v}_1 = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix} \begin{bmatrix} 1/3 \\ 2/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 18 \\ 6 \end{bmatrix}$$

对  $\|\mathbf{x}\|=1$ ,  $\|A\mathbf{x}\|$  的最大值是  $\|A\mathbf{v}_1\| = \sqrt{360} = 6\sqrt{10}$ .

例 1 说明,  $A$  对  $\mathbb{R}^3$  中单位球面的影响与二次型  $\mathbf{x}^T(A^T A)\mathbf{x}$  有关. 事实上, 变换  $\mathbf{x} \rightarrow A\mathbf{x}$  的全部几何特性都可用二次型来说明, 下面我们将说明这个问题.

### 一个 $m \times n$ 矩阵的奇异值

令  $A$  是  $m \times n$  矩阵, 那么  $A^T A$  是对称矩阵且可以正交对角化. 令  $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$  是  $\mathbb{R}^n$  的单位正交基且构成  $A^T A$  的特征向量,  $\lambda_1, \dots, \lambda_n$  是  $A^T A$  对应的特征值, 那么对  $1 \leq i \leq n$ ,

$$\begin{aligned} \|A\mathbf{v}_i\|^2 &= (A\mathbf{v}_i)^T A\mathbf{v}_i = \mathbf{v}_i^T A^T A\mathbf{v}_i \\ &= \mathbf{v}_i^T (\lambda_i \mathbf{v}_i) && \text{由于 } \mathbf{v}_i \text{ 是 } A^T A \text{ 的特征向量} \\ &= \lambda_i && \text{由于 } \mathbf{v}_i \text{ 是单位向量} \end{aligned} \quad (2)$$

所以,  $A^T A$  的所有特征值都非负. 如果必要, 通过重新编号, 可以假设特征值的重新排列满足

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

$A$  的奇异值是  $A^T A$  的特征值的平方根, 记为  $\sigma_1, \dots, \sigma_n$ , 且它们用递减顺序排列, 也就是对  $1 \leq i \leq n$ ,  $\sigma_i = \sqrt{\lambda_i}$ . 由 (2) 可知,  $A$  的奇异值是向量  $A\mathbf{v}_1, \dots, A\mathbf{v}_n$  的长度.

例 2 令  $A$  是例 1 中的矩阵, 由于  $A^T A$  的特征值是 360, 90 和 0, 故  $A$  的奇异值是

$$\sigma_1 = \sqrt{360} = 6\sqrt{10}, \sigma_2 = \sqrt{90} = 3\sqrt{10}, \sigma_3 = 0$$

从例 1 可知,  $A$  的第一个奇异值是  $\|A\mathbf{x}\|$  在所有单位向量处的最大值, 且最大值可以在单位向量  $\mathbf{v}_1$  处获得. 7.3 节的定理 7 表明,  $A$  的第二个奇异值是  $\|A\mathbf{x}\|$  在所有与  $\mathbf{v}_1$  正交的单位向量上的最大值, 且这个最大值可以在第二个单位特征向量  $\mathbf{v}_2$  处获得 (习题 22). 对例 1 中的  $\mathbf{v}_2$ ,

$$A\mathbf{v}_2 = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix} \begin{bmatrix} -2/3 \\ -1/3 \\ 2/3 \end{bmatrix} = \begin{bmatrix} 3 \\ -9 \end{bmatrix}$$

这个点在图 7-13 中椭圆的短轴上, 像  $A\mathbf{v}_1$  在长轴上一样 (见图 7-14). 矩阵  $A$  的前两个奇异值是椭圆长半轴和短半轴的长度.




图 7-14

事实上, 像下面定理所说, 图 7-14 中的  $Av_1$  和  $Av_2$  正交不是偶然.

**定理 9** 假若  $\{v_1, \dots, v_n\}$  是包含  $A^T A$  的特征向量的  $\mathbb{R}^n$  上的单位正交基, 重新整理使得对应的  $A^T A$  的特征值满足  $\lambda_1 \geq \dots \geq \lambda_n$ . 假若  $A$  有  $r$  个非零奇异值, 那么  $\{Av_1, \dots, Av_r\}$  是  $\text{Col } A$  的一个正交基, 且  $\text{rank } A = r$ .

**证** 由于当  $i \neq j$  时,  $v_i$  和  $\lambda_j v_j$  正交, 所以

$$(Av_i)^T (Av_j) = v_i^T A^T A v_j = v_i^T (\lambda_j v_j) = 0$$

从而  $\{Av_1, \dots, Av_n\}$  是一个正交基. 更进一步, 由于向量  $Av_1, \dots, Av_n$  的长度是  $A$  的奇异值, 且因为有  $r$  个非零奇异值, 因此  $Av_i \neq 0$  的充分必要条件是  $1 \leq i \leq r$ . 所以  $Av_1, \dots, Av_r$  是线性无关向量, 且属于  $\text{Col } A$ . 最后, 对任意属于  $\text{Col } A$  的  $y$ , 比如  $y = Ax$ , 我们可以写出  $x = c_1 v_1 + \dots + c_n v_n$ , 且

$$\begin{aligned} y = Ax &= c_1 Av_1 + \dots + c_r Av_r + c_{r+1} Av_{r+1} + \dots + c_n Av_n \\ &= c_1 Av_1 + \dots + c_r Av_r + 0 + \dots + 0 \end{aligned}$$

这样,  $y$  在  $\text{Span}\{Av_1, \dots, Av_r\}$  中, 这说明  $\{Av_1, \dots, Av_r\}$  是  $\text{Col } A$  的一个 (正交) 基. 因此  $\text{rank } A = \dim \text{Col } A = r$ .

**数值计算的注解** 在一些情形下,  $A$  的秩对  $A$  中元素的微小变化很敏感. 如果用计算机对矩阵  $A$  作行化简, 那么很明显矩阵  $A$  的主元列数目的计算方法效果不好, 舍入误差常导致满秩的阶梯矩阵.

实际上, 估计大矩阵  $A$  的秩时, 最可靠的方法是计算非零奇异值的个数. 在这种情形下, 特别小的非零奇异值在实际计算中常假定为零, 矩阵  $A$  的有效秩是剩余非零奇异值的数目.<sup>⊖</sup>

### 奇异值分解

矩阵  $A$  的分解涉及一个  $m \times n$  “对角”矩阵  $\Sigma$ , 其形式是

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix} \begin{matrix} \leftarrow m-r \text{ 行} \\ \uparrow n-r \text{ 行} \end{matrix} \quad (3)$$

其中,  $D$  是一个  $r \times r$  对角矩阵, 且  $r$  不超过  $m$  和  $n$  中较小的那个 (如果  $r$  等于  $m$  或  $n$ , 或都相等,

⊖ 一般地, 秩的估计问题并不简单, 对这个问题的详细讨论见 Philip E. Gill, Walter Murray, and Margaret H. Wright, *Numerical Linear Algebra and Optimization*, vol.1 (Redwood City, CA: Addison-Wesley, 1991), 5.8 节.

则  $M$  中不会出现零矩阵).

### 定理 10 (奇异值分解)

设  $A$  是秩为  $r$  的  $m \times n$  矩阵, 那么存在一个类似 (3) 中的  $m \times n$  矩阵  $\Sigma$ , 其中  $D$  的对角线元素是  $A$  的前  $r$  个奇异值,  $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ , 并且存在一个  $m \times m$  正交矩阵  $U$  和一个  $n \times n$  正交矩阵  $V$  使得  $A = U\Sigma V^T$ .

任何分解  $A = U\Sigma V^T$  称为  $A$  的一个奇异值分解 (或 SVD), 其中  $U$  和  $V$  是正交矩阵,  $\Sigma$  形如 (3) 式,  $D$  具有正的对角线元素. 矩阵  $U$  和  $V$  不是由  $A$  唯一确定的, 但  $\Sigma$  的对角线元素必须是  $A$  的奇异值, 见习题 19. 这样的分解中  $U$  的列称为  $A$  的左奇异向量, 而  $V$  的列称为  $A$  的右奇异向量.

证 假设  $\lambda_i$  和  $\mathbf{v}_i$  如定理 9, 使得  $\{A\mathbf{v}_1, \dots, A\mathbf{v}_r\}$  是  $\text{Col } A$  的正交基. 将每一个  $A\mathbf{v}_i$  单位化得到一个单位正交基  $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ , 其中

$$\mathbf{u}_i = \frac{1}{\|A\mathbf{v}_i\|} A\mathbf{v}_i = \frac{1}{\sigma_i} A\mathbf{v}_i$$

而且

$$A\mathbf{v}_i = \sigma_i \mathbf{u}_i \quad (1 \leq i \leq r) \quad (4)$$

现在将  $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$  扩充为  $\mathbb{R}^m$  的单位正交基  $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$ , 并且取

$$U = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \cdots \quad \mathbf{u}_m] \quad \text{和} \quad V = [\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_n]$$

由构造可知,  $U$  和  $V$  是正交矩阵, 同样由 (4)

$$AV = [A\mathbf{v}_1 \quad \cdots \quad A\mathbf{v}_r \quad \mathbf{0} \quad \cdots \quad \mathbf{0}] = [\sigma_1 \mathbf{u}_1 \quad \cdots \quad \sigma_r \mathbf{u}_r \quad \mathbf{0} \quad \cdots \quad \mathbf{0}]$$

设  $D$  是对角线元素为  $\sigma_1, \dots, \sigma_r$  的对角矩阵,  $\Sigma$  是上面 (3) 中的形式, 那么

$$\begin{aligned} U\Sigma &= [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \cdots \quad \mathbf{u}_m] \left[ \begin{array}{ccc|ccc} \sigma_1 & & & 0 & & \\ & \sigma_2 & & & & 0 \\ & & \ddots & & & \\ & & & \sigma_r & & \\ \hline & & & & 0 & 0 \end{array} \right] \\ &= [\sigma_1 \mathbf{u}_1 \quad \cdots \quad \sigma_r \mathbf{u}_r \quad \mathbf{0} \quad \cdots \quad \mathbf{0}] \\ &= AV \end{aligned}$$

由于  $V$  是一个正交矩阵, 因此  $U\Sigma V^T = AVV^T = A$ . ■

下面的两个例子侧重于讨论奇异值分解的内部结构. 一个有效而数值稳定的分解算法会使用另外一种方法. 参见本节末尾处的“数值计算的注解”.

**例 3** 使用例 1 和例 2 中的结果求  $A = \begin{bmatrix} 4 & 11 & 14 \\ 8 & 7 & -2 \end{bmatrix}$  的一个奇异值分解.

**解** 一个奇异值分解可分三步进行.

**第一步.** 将矩阵  $A^T A$  正交对角化. 即求矩阵  $A^T A$  的特征值及其对应的特征向量的单位正交集. 如果  $A$  只有两列, 则其计算可以手算完成. 对规模较大的矩阵通常需要使用矩阵程序.  $\oplus$

$\oplus$  参阅软件和几何计算器命令的学习指南. 例如, MATLAB 用一个命令 `eig` 就可以求出特征值和特征向量.

而对此处的矩阵  $A$ , 在例 1 中已经给出了  $A^T A$  的特征值及其相应的特征向量.

第二步. 算出  $V$  和  $\Sigma$ . 将  $A^T A$  的特征值按降序排列. 在例 1 中, 特征值已经按降序排列: 360, 90, 0. 它们对应的单位特征向量  $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$  是  $A$  的右奇异向量. 使用例 1 的结果, 构造

$$V = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3] = \begin{bmatrix} 1/3 & -2/3 & 2/3 \\ 2/3 & -1/3 & -2/3 \\ 2/3 & 2/3 & 1/3 \end{bmatrix}$$

特征值的平方根就是奇异值:  $\sigma_1 = \sqrt{360} = 6\sqrt{10}$ ,  $\sigma_2 = \sqrt{90} = 3\sqrt{10}$ ,  $\sigma_3 = 0$ . 其中的非零奇异值是矩阵  $D$  的对角线元素. 矩阵  $\Sigma$  与矩阵  $A$  的行列数相同, 以矩阵  $D$  为其左上角, 其他元素为 0.

$$D = \begin{bmatrix} 6\sqrt{10} & 0 \\ 0 & 3\sqrt{10} \end{bmatrix}, \Sigma = [D \ 0] = \begin{bmatrix} 6\sqrt{10} & 0 & 0 \\ 0 & 3\sqrt{10} & 0 \end{bmatrix}$$

第三步. 构造  $U$ . 当矩阵  $A$  的秩为  $r$  时, 矩阵  $U$  的前  $r$  列是从  $A\mathbf{v}_1 \cdots A\mathbf{v}_r$  计算得到的单位向量. 此例中,  $A$  有两个非零奇异值, 因此  $\text{rank } A = 2$ . 根据例 2 之前的内容和方程 (2), 有  $\|A\mathbf{v}_1\| = \sigma_1$ ,  $\|A\mathbf{v}_2\| = \sigma_2$ , 于是

$$\mathbf{u}_1 = \frac{1}{\sigma_1} A\mathbf{v}_1 = \frac{1}{6\sqrt{10}} \begin{bmatrix} 18 \\ 6 \end{bmatrix} = \begin{bmatrix} 3/\sqrt{10} \\ 1/\sqrt{10} \end{bmatrix}$$

$$\mathbf{u}_2 = \frac{1}{\sigma_2} A\mathbf{v}_2 = \frac{1}{3\sqrt{10}} \begin{bmatrix} 3 \\ -9 \end{bmatrix} = \begin{bmatrix} 1/\sqrt{10} \\ -3/\sqrt{10} \end{bmatrix}$$

留意到  $\{\mathbf{u}_1, \mathbf{u}_2\}$  已是  $\mathbb{R}^2$  的一个基, 因此构造  $U$  不需另外的向量,  $U = [\mathbf{u}_1 \ \mathbf{u}_2]$ .  $A$  的奇异值分解是

$$A = \begin{bmatrix} 3/\sqrt{10} & 1/\sqrt{10} \\ 1/\sqrt{10} & -3/\sqrt{10} \end{bmatrix} \begin{bmatrix} 6\sqrt{10} & 0 & 0 \\ 0 & 3\sqrt{10} & 0 \end{bmatrix} \begin{bmatrix} 1/3 & 2/3 & 2/3 \\ -2/3 & -1/3 & 2/3 \\ 2/3 & -2/3 & 1/3 \end{bmatrix}$$

$\uparrow$   
 $U$

$\uparrow$   
 $\Sigma$

$\uparrow$   
 $V^T$

例 4 求  $A = \begin{bmatrix} 1 & -1 \\ -2 & 2 \\ 2 & -2 \end{bmatrix}$  的一个奇异值分解.

解 首先, 计算  $A^T A = \begin{bmatrix} 9 & -9 \\ -9 & 9 \end{bmatrix}$ .  $A^T A$  的特征值是 18 和 0, 相应的单位特征向量是

$$\mathbf{v}_1 = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$$

这两个单位向量构成  $V$  的列:

$$V = [\mathbf{v}_1 \ \mathbf{v}_2] = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

矩阵的奇异值为  $\sigma_1 = \sqrt{18} = 3\sqrt{2}$ ,  $\sigma_2 = 0$ . 因为只有一个非零的奇异值, 所以“矩阵”  $D$  可写成单个数值, 即  $D = 3\sqrt{2}$ . 矩阵  $\Sigma$  与矩阵  $A$  的行列数相同, 以矩阵  $D$  为其左上角:

$$\Sigma = \begin{bmatrix} D & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 3\sqrt{2} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

为构造  $U$ , 首先构造  $Av_1$  和  $Av_2$ :

$$Av_1 = \begin{bmatrix} 2/\sqrt{2} \\ -4/\sqrt{2} \\ 4/\sqrt{2} \end{bmatrix}, \quad Av_2 = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

为检查计算, 验证  $\|Av_1\| = \sigma_1 = \sqrt{18} = 3\sqrt{2}$ . 当然,  $Av_2 = 0$ , 因为  $\|Av_2\| = \sigma_2 = 0$ . 目前只找到  $U$  的一列是

$$u_1 = \frac{1}{3\sqrt{2}} Av_1 = \begin{bmatrix} 1/3 \\ -2/3 \\ 2/3 \end{bmatrix}$$

$U$  的其他列是将集合  $\{u_i\}$  扩充为  $\mathbb{R}^3$  的单位正交基而得到的. 此时, 我们需要两个单位正交向量  $u_2$  和  $u_3$  且都与  $u_1$  正交. (见图 7-15.) 每个向量必须满足  $u_1^T x = 0$ , 这等价于方程  $x_1 - 2x_2 + 2x_3 = 0$ , 该方程的解集构成的基是

$$w_1 = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}, \quad w_2 = \begin{bmatrix} -2 \\ 0 \\ 1 \end{bmatrix}$$

(经检验  $w_1$  和  $w_2$  都与  $u_1$  正交.) 应用格拉姆-施密特方法 (和标准化) 于  $\{w_1, w_2\}$ , 可以得到

$$u_2 = \begin{bmatrix} 2/\sqrt{5} \\ 1/\sqrt{5} \\ 0 \end{bmatrix}, \quad u_3 = \begin{bmatrix} -2/\sqrt{45} \\ 4/\sqrt{45} \\ 5/\sqrt{45} \end{bmatrix}$$

最后, 令  $U = [u_1 \ u_2 \ u_3]$ , 以及由上所得的  $V^T$  和  $\Sigma$ , 有

$$A = \begin{bmatrix} 1 & -1 \\ -2 & 2 \\ 2 & -2 \end{bmatrix} = \begin{bmatrix} 1/3 & 2/\sqrt{5} & -2/\sqrt{45} \\ -2/3 & 1/\sqrt{5} & 4/\sqrt{45} \\ 2/3 & 0 & 5/\sqrt{45} \end{bmatrix} \begin{bmatrix} 3\sqrt{2} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$




图 7-15

## 奇异值分解的应用

如上所述, 奇异值分解常用于估计矩阵的秩. 下面简单叙述它在数值计算中的其他应用, 7.5 节给出一个奇异值分解在图像处理中的应用.

**例 5 (条件数)** 当应用矩阵  $A$  的奇异值分解时, 多数涉及方程  $Ax = b$  的数值计算要尽可能地可靠. 两个正交矩阵  $U$  和  $V$  不影响向量的长度和两个向量的夹角 (6.2 节定理 7). 数值计算中的任何不稳定因素都与  $\Sigma$  有关. 如果  $A$  的奇异值非常大或非常小, 则舍入误差几乎不可避

免, 此时, 知道  $\Sigma$  和  $V$  中的元素对分析误差特别有用.

如果  $A$  是一个  $n \times n$  可逆矩阵, 那么最大奇异值和最小奇异值的比率  $\sigma_1 / \sigma_n$  给出了矩阵  $A$  的条件数. 2.3 节的习题 41~43 表明条件数如何影响  $Ax = b$  的解对  $A$  的元素变化 (或误差) 的敏感程度 (事实上,  $A$  的“条件数”可用几种方式计算, 但这里给出的定义可广泛用于  $Ax = b$  的研究).

**例 6 (基本子空间的基)** 给定  $m \times n$  矩阵  $A$  的一个奇异值分解, 取  $u_1, \dots, u_m$  是左奇异向量,  $v_1, \dots, v_n$  是右奇异向量, 且  $\sigma_1, \dots, \sigma_r$  是奇异值,  $r$  为  $A$  的秩. 由定理 9,

$$\{u_1, \dots, u_r\} \quad (5)$$

是  $\text{Col } A$  的一个单位正交基. 见图 7-16.

回忆 6.1 节的定理 3,  $(\text{Col } A)^\perp = \text{Nul } A^T$ , 因此

$$\{u_{r+1}, \dots, u_m\} \quad (6)$$

是  $\text{Nul } A^T$  的一个单位正交基.

由于当  $1 \leq i \leq n$  时  $\|Av_i\| = \sigma_i$ , 且  $\sigma_i$  是零的充分必要条件是  $i > r$ , 因此向量  $v_{r+1}, \dots, v_n$  生成一个维数为  $n-r$  的子空间  $\text{Nul } A$ . 由秩定理可知,  $\dim \text{Nul } A = n - \text{rank } A$ , 从而说明

$$\{v_{r+1}, \dots, v_n\} \quad (7)$$

是  $\text{Nul } A$  的一个单位正交基, 见 4.5 节的基定理.

从 (5) 和 (6) 可知, 空间  $\text{Nul } A^T$  的正交补是  $\text{Col } A$ . 将  $A$  和  $A^T$  交换, 我们有

$$(\text{Nul } A)^\perp = \text{Col } A^T = \text{Row } A$$

因此, 从 (7) 得

$$\{v_1, \dots, v_r\} \quad (8)$$

是  $\text{Row } A$  的一个单位正交基.

图 7-17 给出 (5)~(8) 的总结, 但说明的是  $\{\sigma_1 u_1, \dots, \sigma_r u_r\}$  为  $\text{Col } A$  的正交基, 而不是标准基. 注意到对  $1 \leq i \leq r$ ,  $Av_i = \sigma_i u_i$ .

由  $A$  确定的四个基本子空间的单位正交基在某些计算中非常有 用, 特别是在条件优化问题中更是如此.




图 7-16 例 6 中的基本子空间




图 7-17 四个基本子空间和  $A$  的作用

四个基本子空间和奇异值的概念给可逆矩阵定理提供了最后的命题。(回忆为了避免几乎将可逆矩阵定理的命题数目翻倍,定理中已将与 $A^T$ 有关的命题删除了.)可逆矩阵定理的其他命题在2.3节、2.9节、3.2节、4.6节和5.2节中已经给出.

**定理** (可逆矩阵定理(最后补充))

设 $A$ 为 $n \times n$ 矩阵,那么下述命题中的每一个都与 $A$ 是可逆矩阵的命题等价.

u.  $(\text{Col } A)^\perp = \{\mathbf{0}\}$ .

v.  $(\text{Nul } A)^\perp = \mathbb{R}^n$ .

w.  $\text{Row } A = \mathbb{R}^n$ .

x.  $A$ 有 $n$ 个非零的奇异值.

**例7** (奇异值分解的简化和 $A$ 的伪逆) 当 $\Sigma$ 包含零元素的行或列时,矩阵 $A$ 具有更简洁的分解.利用上面建立的符号,取 $r = \text{rank } A$ ,将 $U$ 和 $V$ 矩阵分块为第一块包含 $r$ 列的子矩阵:

$$U = [U_r \quad U_{m-r}], \quad \text{其中 } U_r = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_r] \\ V = [V_r \quad V_{n-r}], \quad \text{其中 } V_r = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_r]$$

那么 $U_r$ 是 $m \times r$ ,  $V_r$ 是 $n \times r$ . (为简化符号,我们考虑 $U_{m-r}$ 和 $V_{n-r}$ ,即使其中一个没有任何列.)分块矩阵的乘法表明

$$A = [U_r \quad U_{m-r}] \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} V_r^T \\ V_{n-r}^T \end{bmatrix} = U_r D V_r^T \quad (9)$$

矩阵 $A$ 的这个分解称为 $A$ 的简化的奇异值分解.由于 $D$ 的对角线元素非零,因此 $D$ 是可逆矩阵.下面的矩阵称为 $A$ 的伪逆(也称穆尔-彭罗斯逆):

$$A^+ = V_r D^{-1} U_r^T \quad (10)$$

本章最后的补充习题12~14研究了简化的奇异值分解和伪逆的一些性质. ■

**例8** (最小二乘解) 给定方程 $A\mathbf{x} = \mathbf{b}$ ,利用式(10)中给出的 $A$ 的伪逆,定义

$$\hat{\mathbf{x}} = A^+ \mathbf{b} = V_r D^{-1} U_r^T \mathbf{b}$$

那么由(9)式中的奇异值分解得到

$$\begin{aligned} A\hat{\mathbf{x}} &= (U_r D V_r^T)(V_r D^{-1} U_r^T \mathbf{b}) \\ &= U_r D D^{-1} U_r^T \mathbf{b} && \text{由于 } V_r^T V_r = I_r \\ &= U_r U_r^T \mathbf{b} \end{aligned}$$

从(5)式可知, $U_r U_r^T \mathbf{b}$ 是 $\mathbf{b}$ 在 $\text{Col } A$ 上的正交投影 $\hat{\mathbf{b}}$ (见6.3节定理10),因此 $\hat{\mathbf{x}}$ 是 $A\mathbf{x} = \mathbf{b}$ 的最小二乘解.实际上,这个 $\hat{\mathbf{x}}$ 在 $A\mathbf{x} = \mathbf{b}$ 的所有最小二乘解中具有最小长度,见补充习题14. ■

**数值计算的注解** 例1~4和习题说明了奇异值的概念并给出如何手工计算.实际上,应该避免 $A^T A$ 的计算,原因是任何 $A$ 中元素的误差在 $A^T A$ 中被平方.存在快速的迭代方法,可计算精确到很多位数的矩阵 $A$ 的奇异值和奇异向量.



## 进一步阅读

Horn, Roger A., and Charles R. Johnson, *Matrix Analysis*®, vol. 1 (Cambridge: Cambridge University Press, 1985), pp. 414–445.

Long, Cliff, “Visualization of Matrix Singular Value Decomposition.” *Mathematics Magazine* **56** (1983), pp. 161–167.

Moler, C. B., and D. Morrison, “Singular Value Analysis of Cryptograms.” *Amer. Math. Monthly* **90** (1983), pp. 78–87.

Strang, Gilbert, *Linear Algebra and Its Applications*, 3rd ed. (San Diego: Harcourt Brace Jovanovich, 1988), pp. 442–452.

Watkins, David S., *Fundamentals of Matrix Computations* (New York: Wiley, 1991), pp. 390–398, 409–421.

## 练习题

- 给定一个奇异值分解  $A = U\Sigma V^T$ , 求  $A^T$  的一个奇异值分解.  $A$  和  $A^T$  的奇异值之间有什么联系?
- 对任意的  $n \times n$  矩阵  $A$ , 利用奇异值分解证明存在一个  $n \times n$  的正交阵  $Q$ , 使得  $A^T A = Q^T (A^T A) Q$ .

注: 练习题 2 表明对任意的  $n \times n$  矩阵  $A$ , 矩阵  $AA^T$  和  $A^T A$  的正交相似的.

## 习题 7.4

求习题 1~4 中矩阵的奇异值分解.

- $\begin{bmatrix} 1 & 0 \\ 0 & -3 \end{bmatrix}$
- $\begin{bmatrix} -3 & 0 \\ 0 & 0 \end{bmatrix}$
- $\begin{bmatrix} 2 & 3 \\ 0 & 2 \end{bmatrix}$
- $\begin{bmatrix} 3 & 0 \\ 8 & 3 \end{bmatrix}$

求习题 5~12 中每个矩阵的奇异值分解. (提示: 在习题 11 中,  $U$  的一个选择可以是

$$\begin{bmatrix} -1/3 & 2/3 & 2/3 \\ 2/3 & -1/3 & 2/3 \\ 2/3 & 2/3 & -1/3 \end{bmatrix}, \text{ 习题 12 中 } U \text{ 的一个列可以}$$

$$\begin{bmatrix} 1/\sqrt{6} \\ -2/\sqrt{6} \\ 1/\sqrt{6} \end{bmatrix}.)$$

- $\begin{bmatrix} -2 & 0 \\ 0 & 0 \end{bmatrix}$
- $\begin{bmatrix} -3 & 0 \\ 0 & -2 \end{bmatrix}$
- $\begin{bmatrix} 2 & -1 \\ 2 & 2 \end{bmatrix}$
- $\begin{bmatrix} 4 & 6 \\ 0 & 4 \end{bmatrix}$
- $\begin{bmatrix} 3 & -3 \\ 0 & 0 \\ 1 & 1 \end{bmatrix}$
- $\begin{bmatrix} 7 & 1 \\ 5 & 5 \\ 0 & 0 \end{bmatrix}$

$$11. \begin{bmatrix} -3 & 1 \\ 6 & -2 \\ 6 & -2 \end{bmatrix} \quad 12. \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ -1 & 1 \end{bmatrix}$$

$$13. \text{ 求 } A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{bmatrix} \text{ 的奇异值分解 (提示: 对 } A^T$$

进行分解).

- 在习题 7 中, 求一个单位向量  $x$ , 使得  $Ax$  具有最大长度.
- 假设下面是矩阵  $A$  的奇异值分解, 其中  $U$  和  $V$  的元素是四舍五入精确到小数点后两位数字.

$$A = \begin{bmatrix} 0.40 & -0.78 & 0.47 \\ 0.37 & -0.33 & -0.87 \\ -0.84 & -0.52 & -0.16 \end{bmatrix} \begin{bmatrix} 7.10 & 0 & 0 \\ 0 & 3.10 & 0 \\ 0 & 0 & 0 \end{bmatrix} \\ \times \begin{bmatrix} 0.30 & -0.51 & -0.81 \\ 0.76 & 0.64 & -0.12 \\ 0.58 & -0.58 & 0.58 \end{bmatrix}$$

- $A$  的秩是多少?
- 利用  $A$  的这个分解, 不用计算, 写出  $\text{Col } A$  的一个基和  $\text{Nul } A$  的一个基. (提示: 首先写出  $V$  的列.)

- 对下列  $3 \times 4$  矩阵  $A$  的奇异值分解, 重做习题 15.